

Билет 1

Смп. 1

Модель нейрона Машалова-Миткея, Перцептрон Розенблатта, Теорема Новикова, Полносвязные нейронные сети

- 1) $X = (x_1, \dots, x_n)$, нейрон $a(x)$ вычисляет n -связную булеву функцию: $a(x) = \text{Heaviside}(\sum_{i=1}^n w_i x_i - w_0)$, w -веса ($w_i > 0$ - возб., $w_i < 0$ - тормоз.), w_0 - порог
- 2) Виды элементов: S - сенсорный эл-т, A - ассоциативный эл-т, U - инт., W - сумм. элемент. S - элемент, A - элемент, U - элемент, W - элемент. Если количество сигналов S на его входе превышает некоторое значение θ . Значит сигнал идет от каждого элемента A идет на сумматор R с весом w_j - весом A - R связи (веса S - A принимаются ± 1 или 1) значение порога θ задано и неизменно, общ. вид ф-ции, реализующей R -эл-т, представим как перцептрон $x) = \text{sgn}(\sum_{i=1}^n w_i x_i - \theta)$
- 3) Т. Новикова и правило Хэбба: Пусть мы во пре-дметной области $Y = \{-1, +1\}$, x - объект обуч. выборки $X^e = \{x_i, y_i\}_{i=1}^l$, $y_i = y_i^*(x_i) \in Y$ - класс. Алг. максим. имеем вид $a(x, w) = \text{sgn}(\langle x, w \rangle)$, ошибка вычисляется, если $\langle x, w \rangle$ не совпал со значением y_i , т.е. $\langle x, w \rangle y_i < 0$. Можно модифицировать веса: $w \rightarrow w + \eta x y$
- Содержательно теорема: $X \subset \mathbb{R}^{n+1}$, $Y = \{-1, 1\}$, X^e - мин. разделение, т.е. $\exists w^*$ и $\delta > 0$ т.ч. $\langle x_i, w^* \rangle y_i > \delta \forall i = 1, \dots, l$. Тогда алгоритм может найти вектор весов, разд. train без ошибок за кон. число итераций \forall нач. приближ. w_0 и $\eta > 0$.

* FCN: input $\rightarrow x \rightarrow xw + b \rightarrow \sigma \rightarrow$ output
dense layer - мин. преобр. входн. данных (обуч. пер-мемприца w и вектор b): $x \mapsto xw + b$, $w \in \mathbb{R}^{d \times k}$, $x \in \mathbb{R}^d$, $b \in \mathbb{R}^k$
Слой делает d -мерные векторы k -мерные.
activation - нелин. преобр.

Билет 2

Аппрокс. теорема (Б.Д.). Пушкин, Колмогорова-Арнольда, Унбесенно

- 1) Пушкин: Визмеримой f на (a, b) и $\forall \epsilon > 0 \exists f_\epsilon \in C[a, b]$, такая что $f = f_\epsilon$ везде кроме некоторого m -ва меры ϵ .

т.е. $\forall x \in [a, b]: f(x) \neq f_2(x) \leq \epsilon$

Смп. 2

Теорема Коши-Вейерштрасса: Всякая непрерывная функция на отрезке $[a, b]$ равномерно непрерывна.

т.е. $\forall \epsilon > 0, \exists \delta > 0, \forall x, y \in [a, b], |x - y| < \delta \Rightarrow |f(x) - f(y)| < \epsilon$

Универсальное аппроксимирование: $f = \sum_{q=0}^{\infty} \Phi(\sum_{p=1}^n \lambda_p \Phi(x_p + \gamma(q) + \gamma))$, $\gamma, \lambda \in \mathbb{R}$, $\Phi \in C$, $\Phi: \mathbb{R} \rightarrow \mathbb{R}$, $\Phi[0, 2] \rightarrow \mathbb{R}$.

Условие: $Kf \in C^q(\mathbb{R})$, $f: \mathbb{R} \rightarrow \mathbb{R}$, $\forall \epsilon > 0 \exists N, w_1, \dots, w_N, b_1, \dots, b_N$, $\lambda_1, \dots, \lambda_N: |f - \sum_{i=1}^N \lambda_i \sigma(\langle x, w_i \rangle + b_i)| < \epsilon \forall x \in [0, 1]^m \in \mathbb{R}^m$

Бунет 3

Обучение нейронных сетей: stochastic gradient descent, back-propagation.

Минимизация функции: $Q(w) = \sum h(w, x_i, y_i) \rightarrow \min$

$w = w - \gamma h_i(w)$, $\nabla h_i(w) = \left(\frac{\partial h_i(w)}{\partial w^k} \right)_{k=1}^m$, $Q = (1 - \lambda)Q + \lambda h_i(w)$

Back drop

Дано $(x_i, y_i)_{i=1}^n$, сеть $(H_e)_{e=1}^n$, параметры γ, λ . Учим сеть

Берем все веса $w = (w^1, \dots, w^n)$

1) random $(x_i) \in X^e$, $e = 1, \dots, h$, $n = 1, \dots, H_e$

forward: $x_{in}^e = \sigma_n^e \left(\sum_{k=0}^{H_{e-1}} w_{kn}^e x_{in}^{e-1} \right)$, $p_{ni}^h = \frac{\partial h_i(w)}{\partial x_n^w}$
 $z_{in}^e = \left(\sigma_n^e \right)' \left(\sum_{k=0}^{H_{e-1}} w_{kn}^e x_{in}^{e-1} \right)$

backward: $p_{in}^e = \sum_{h=0}^{H_e} p_{in}^h z_{in}^h w_{kn}^e$


grad step for all $e = 1, \dots, h$, $k = 0, \dots, H_{e-1}$, $n = 1, \dots, H_e$

$w_{kn}^e = w_{kn}^e - \gamma p_{in}^e z_{in}^e x_{in}^{e-1}$

Почему Q и/или веса нестабильны

Пример: ③ $\frac{\partial P}{\partial h_1}, \frac{\partial P}{\partial h_2}$ ② $\frac{\partial P}{\partial z_1} = \frac{\partial P}{\partial h_1} \frac{\partial h_1}{\partial z_1} = \frac{\partial P}{\partial h_1} \frac{\partial h_2}{\partial z_1}$; $\frac{\partial P}{\partial z_2} = \frac{\partial P}{\partial h_1} \frac{\partial h_1}{\partial z_2} + \frac{\partial P}{\partial h_2} \frac{\partial h_2}{\partial z_2}$

① $\frac{\partial P}{\partial x_1} = \frac{\partial P}{\partial h_1} \frac{\partial h_1}{\partial z_1} \frac{\partial z_1}{\partial x_1} + \frac{\partial P}{\partial h_2} \frac{\partial h_2}{\partial z_1} \frac{\partial z_1}{\partial x_1} + \frac{\partial P}{\partial h_1} \frac{\partial h_1}{\partial z_2} \frac{\partial z_2}{\partial x_1} + \frac{\partial P}{\partial h_2} \frac{\partial h_2}{\partial z_2} \frac{\partial z_2}{\partial x_1}$



Бунет 4


Метод обучения Adaptive momentum.

Метод Drop-out new neurons

① $v_0 = 0$, $v_{k+1} = \beta_1 v_k + (1 - \beta_1) \nabla f(x_k)$, $x_{k+1} = x_k - \frac{\epsilon_2}{\sqrt{G_{k+1} + \epsilon}} v_{k+1}$, $G_{k+1} = \beta_2 G_k + (1 - \beta_2) (\nabla f(x_k))^2$, $\beta_1 = 0.5$, $\beta_2 = 0.95$, $\epsilon = 1e-8$, $f(x) = \sum h(x, y_i)$

Нормы и momentum - RMS prop.

Задача 3



RMS Prop: $G_{k+1} = \sqrt{G_k + (1-\alpha)(\nabla f(x_k)^2)}$
 $x_{k+1} = x_k - \frac{\eta}{\sqrt{G_{k+1}} + \epsilon} \nabla f(x_k)$

Dropout

При град. нате $h_i(w) \rightarrow m_i$ единицы n-ой нейрон
 l -го слоя с вер. p_c

$x_{n_i}^l = \xi_n^l \sigma_n^l / (\sum w_{kn}^l x_{k_i}^{l-1})$ $P_2(\xi_n^l = 0) = p_c$

Вектор c $(1-p_c)$

на обд. $x_{n_i}^l = \frac{1}{1-p_c} \xi_n^l \sigma_n^l (\sum w_{kn}^l x_{k_i}^{l-1})$

на батчах $x_{n_i}^l = \sigma_n^l (\sum w_{kn}^l x_{k_i}^{l-1})$


в среднем h_2 gradstep $w = w(1-\eta) - \eta \frac{1}{1-p_c} \xi_n^l h_i'(w)$

Задача 5

Основные способы регуляризации:
 Оверфит, skip-connection, drop-out, batch norm,
 инициализация.

1) Дано 2 матрицы $A(n_x \times n_y)$ и $B(m_x \times m_y)$ $C = A * B$ C shape:
 $= (n_x - m_x + 1), (n_y - m_y + 1)$, т.е. $C_{i,j} = \sum_{k=0}^{m_x-1} \sum_{l=0}^{m_y-1} A_{i+k,j+l} B_{k,l}$

2) Skip-connection решает проблему затухания grad, передавая инфор. из нижних слоев в верхние:



3) Dropout - случайное выключение некоторых из нейронов для борьбы с переобучением и уменьшения обобщающей способности

4) Batch norm - стабилизирует дисперсию от входа. Даны n наблюдений x_1, \dots, x_n $\mu_B = \frac{1}{n} \sum x_i$ $\sigma_B^2 = \frac{1}{n} \sum (x_i - \mu_B)^2$

Batch := $\{x_1, \dots, x_n\}$ $\mu_B = \frac{1}{n} \sum x_i$ $\sigma_B^2 = \frac{1}{n} \sum (x_i - \mu_B)^2$
 $\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}$ $y_i = f(\hat{x}_i; \beta) = \text{Batch Norm}(x_i)$ - отнорм. и обн.


5) ~~on-line~~ инициализация помогает моделировать сложные зависимости.

Рекуррентные нейронные сети LSTM

RNN-сети с циклами, позволяющие им обрабатывать последовательности, где будущее зависит от прошлого. Они решают проблему Vanishing Through Time, которую мы знаем.




Схема с задержкой в скрытом слое:



- Виды RNN:
- 1) 1 вход, много выходов: для измерения аудио
 - 2) много входов и выходов: для оценки последовательностей
 - 3) много входов и выходов: для перевода


LSTM



шаг 1



шаг 2



шаг 3



шаг 4



$$C_t = f_t C_{t-1} + i_t \tilde{C}_t$$

$$\tilde{C}_t = \sigma(W_i [h_{t-1}, x_t] + b_i)$$

$$f_t = \sigma(W_f [h_{t-1}, x_t] + b_f)$$

$$h_t = \sigma(W_o [h_{t-1}, x_t] + b_o) \tanh(C_t)$$

Метод опорных векторов.

Kernel trick.

Составим задачу регрессии - дано $\text{train } X = \{(x_i, y_i)\}_{i=1}^p$
 найти $g(x)$ - универсальную функцию наилучшим образом.
 loss: $h(y, g(x)) = \rho(0, |y - g(x)|) \leq \varepsilon$ $\varepsilon > 0$
 $\rho(z) = |z| - \varepsilon, |z| > \varepsilon; 0, |z| \leq \varepsilon$

ищем решение в линейном виде $f(x) = (w, x) - w_0$
 loss: $q(x_i) = |(w, x_i) - w_0 - y_i| \leq \varepsilon \forall (x_i, y_i) \in \text{train}$ где $|z|_k = \max(0, |z| - \varepsilon)$

функционал, минимизируем

$$Q_\varepsilon(w, w_0) = \sum_{i=1}^p |(w, x_i) - w_0 - y_i| + \gamma (w, w)^2 \rightarrow \min_{w, w_0}$$

Введем переменные ξ_i^+ и ξ_i^- - штраф. который = 0 при выполнении или замещениям условия

$$\xi_i^+ = (a(x_i) - y_i - \varepsilon)_+, \quad \xi_i^- = (-a(x_i) + y_i - \varepsilon)_+ \quad i=1, \dots, p$$

Задача минимизации:

$$\begin{cases} 0.5 (w, w)^2 + \frac{1}{2\gamma} \sum_{i=1}^p (\xi_i^+ + \xi_i^-) \rightarrow \min_{w, w_0, \xi_i^+, \xi_i^-} \\ (w, x_i) - w_0 \leq y_i + \varepsilon + \xi_i^+ \\ (w, x_i) - w_0 \geq y_i - \varepsilon - \xi_i^- \\ \xi_i^- \geq 0, \xi_i^+ \geq 0 \end{cases}$$

Будем решать двойственную задачу, макс. произв. замещения
 отор $k(x_i, x_j)$, d_i^+, d_i^- - двойств. перемен.

$$\begin{cases} h(d^+, d^-) = -\varepsilon \sum_{i=1}^p (d_i^+ + d_i^-) + \sum_{i,j=1}^p (d_i^- - d_i^+) y_i - \frac{1}{2} \sum_{i,j=1}^p (d_i^- - d_i^+) (d_j^- - d_j^+) \cdot k(x_i, x_j) \rightarrow \max_{d_i^+, d_i^-} \\ 0 \leq d_i^+ \leq c = \frac{1}{2\gamma}, \quad 0 \leq d_i^- \leq c \\ \sum (d_i^+ + d_i^-) \rightarrow 0 \end{cases}$$

В рег. все x_i известны на 5 минув

- 1) $|a(x_i) - y_i| \leq \varepsilon \quad d_i^+ = d_i^- = \xi_i^+ = \xi_i^- = 0$
- 2) $a(x_i) = y_i + \varepsilon \quad 0 \leq d_i^+ < c, \quad d_i^- = \xi_i^+ = \xi_i^- = 0$
- 3) $a(x_i) = y_i - \varepsilon \quad 0 \leq d_i^- < c, \quad d_i^+ = \xi_i^+ = \xi_i^- = 0$
- 4) $a(x_i) > y_i + \varepsilon \quad d_i^+ = c, \quad d_i^- = 0, \quad \xi_i^+ = a(x_i) - y_i - \varepsilon, \quad \xi_i^- = 0$
- 5) $a(x_i) < y_i - \varepsilon \quad d_i^+ = 0, \quad d_i^- = c, \quad \xi_i^+ = 0, \quad \xi_i^- = y_i - a(x_i) - \varepsilon$

7.5 - опорные, ут. в вып. веков. Упрощенно $\sum (d_i^- - d_i^+) k(x_i, x) - w_0$

$$w_0: (w, x_i) - w_0 = \begin{cases} y_i + \varepsilon, & \xi_i \in \mathbb{R}^+ \\ y_i - \varepsilon, & \xi_i \in \mathbb{R}^- \end{cases}$$

классификация:

$\varphi: \mathbb{R}^n \rightarrow H$, H - вып. пр-во. сразу сводим задачу к мин. разд. выборке
 разд. φ - это $f(x) = (w, \varphi(x)) + b$, $w = \sum d_i y_i \varphi(x_i)$, где d_i зависит от y_i и $(\varphi(x_i), \varphi(x_j))$, преем $k(x, y) = (\varphi(x), \varphi(y))$, k неотр. опр. и сим.

В случае мин. разд. выборки ищем $f(x)$ т.т. $f(x_i) > 0 \forall x_i \in \omega_1, f(x_i) < 0$
 $\forall x \in \omega_2, y_i = \begin{cases} 1, & x \in \omega_1 \\ -1, & x \in \omega_2 \end{cases}$ т.е. $y_i (w, x_i) + b \geq 0$

Разд. гиперплоскостью $(w, x) + b = 0$ по 7-му критерию задача свод. $h(w, b, d) = 0, 5 (w, w) - \varepsilon \sum d_i y_i ((w, x_i) + b) - 1 \rightarrow \min_{w, b, d}$

$\lambda_i \geq 0, d_i (y_i (w, x_i) + b - 1) = 0$, иначе $\lambda_i = 0$ или $y_i ((w, x_i) + b - 1) = 0$, y_i ген. сущ. одной нормы:

$$\begin{cases} \frac{\partial h}{\partial w_s} = w_s - \sum d_i y_i x_{is} = 0 \\ \frac{\partial h}{\partial b} = \sum d_i y_i = 0 \end{cases} \Rightarrow w = \sum d_i y_i x_i \text{ и } \sum d_i y_i = 0$$

$$h(w, b, d) = \sum d_i - 0.5 \sum d_i d_j y_i y_j (x_i, x_j) = \sum d_i - 0.5 \| \sum d_i y_i x_i \|^2 \text{ т.е.}$$

вводим и помечены при макс. $\Phi(d) = \sum d_i - 0.5 \| \sum d_i y_i x_i \|^2$

kernel trick

$$w = \sum d_i y_i \varphi(x_i) \text{ argmax } f(d_1, \dots, d_n) = \sum d_i - \frac{1}{2} \sum_{i,j} \sum y_i d_i k(x_i, x_j) y_j d_j$$

$$\sum d_i y_i = 0, 0 \leq d_i \leq \frac{1}{\lambda \lambda_i} \lambda_i, \varphi(x_i) \text{ решим на граде в прободр. пр-во}$$

$$\text{иногда } b = w^T \varphi(x_i) - y_i = \sum y_j d_j k(x_j, x_i) - y_i; z \mapsto \text{sgn}(w^T \varphi(z) - b)$$

Букет 6

Метод и-близких соседей Оценка
симметричности, массового метода kNN
(метод Ховера-Харфа)

Ран: $\text{train } X^m = \{(x_i, y_i)\}_{i=1}^m$, метрика $\rho(x, x')$ для произв. объектов, ранжировав объектов x_i в порядке возр. до u : $\rho(u, x_1, u) \leq \rho(u, x_m, u)$
 x_i и u соседей и тогда алгоритм будет задавать класс
 $a(u) = \text{argmax}_y \sum [y_i = y] w(i, u)$ где $w(i, u)$ весовый коэффициент
пока i -й сосед для u . Для массового kNN $w(i, u) =$
 $= [i \leq k]$ при k -м сосед $w(i, u)$ на-во м.б. любым, тогда приме-
ним одо пример: $w(i, u) = \frac{1}{k} \left(\frac{\rho(u, x_i, u)}{\rho(u, x_k, u)} \right)$ - пороговое или
и-во Ховера-Харфа: верхняя граница погрешности $R^* \leq R_{kNN} \leq R^*$
 $= (1 - \frac{R^*}{M-1})$, R^* - погрешность R_{kNN} - оценка погрешности, M - число соседей

Букет 9

Задача классификации Основание
метрики (confusion matrix, ROC AUC) и т.д. Оценка
объекта, классификация модели.

Задача: Ранж. зад. бинар. классификацией $x \rightarrow y, x \in \mathbb{R}^n, y \in \{+1, -1\}$
 $X^m = \{(x_i, y_i)\}_{i=1}^m$, число $a = \text{sgn}(\langle w, x \rangle - w_0)$, ищем параметр w , мин.
риск $R(x^m, w, w_0) = \sum [a \neq y_i] = \sum [\langle w, x_i \rangle > w_0, y_i < 0]$
ассимптот. $= \frac{1}{n} \sum_{i=1}^n [a(x_i) = y_i] = \frac{TP + TN}{FP + FN + TP + TN}$ Матр. ошибок:

При обучении w_0 много x_i т.е. $a(x_i) = -1$
добавн. dy-коэффициент, тогда $\text{loss} = d_y [a(x_i) \neq y_i]$
ROC-AUC по x : $\text{TPR} = \frac{\sum [y_i = +1] [a(x_i) = +1]}{\sum [y_i = +1]}$, по y : $\text{TPR} = \frac{\sum [y_i = +1] [a(x_i) = +1]}{\sum [y_i = +1]}$

Оценки обобщ. способности: $X^e = \{(x_i, y_i)\}_{i=1}^e$
 $y_i = y^*(x_i)$ $A_+ = \{a, x \rightarrow y\}$, $A_- = \{x \rightarrow y\} \xrightarrow{\text{обуч.}} A_+$

$h(a, x) = \text{loss } Q(a, x^e) = \frac{1}{e} \sum \mathcal{L}(a, x_i)$ - оценка потерь

Самый common: fold-out $X^e = X_n^e \cup X_{n+1}^e, n = 1, \dots, N$

$\text{cross-val}(u, X^e) = \frac{1}{N} \sum_{n=1}^N Q_n(X_n^e, X_{n+1}^e)$